Calcul asynchrone en Python

Utilisation de la librairie `dask`

M. Ben & R. Tavenard

Calcul asynchrone

- Principe : lancer plusieurs calculs en parallèle sans attendre la fin de l'un pour débuter le suivant
- Map-reduce est un cas particulier
- Il existe des cas plus complexes
  Exemple :

(3 + 7) * (2 + 8) * ((2 * 3) - 1)

Calcul asynchrone

- Principe : lancer plusieurs calculs en parallèle sans attendre la fin de l'un pour débuter le suivant
- Map-reduce est un cas particulier
- Il existe des cas plus complexes
  Exemple :

(3 + 7) * (2 + 8) * ((2 * 3) - 1)

Calcul asynchrone

- Principe : lancer plusieurs calculs en parallèle sans attendre la fin de l'un pour débuter le suivant
- Map-reduce est un cas particulier
- Il existe des cas plus complexes
  Exemple :

(3 + 7) * (2 + 8) * ((2 * 3) - 1)

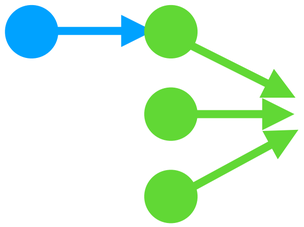

Calcul asynchrone

- Principe : lancer plusieurs calculs en parallèle sans attendre la fin de l'un pour débuter le suivant
- Map-reduce est un cas particulier
- Il existe des cas plus complexes
  Exemple :

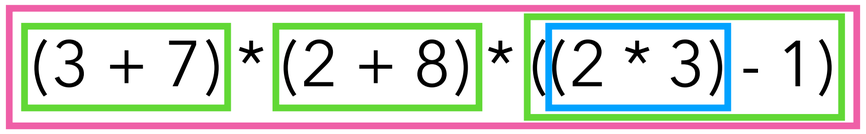

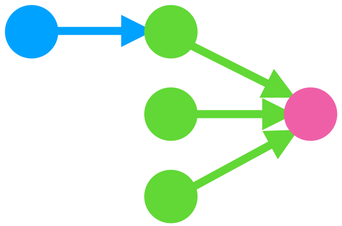

Calcul asynchrone en Python

Utilisation de la librairie `dask`

- Décoration de fonctions

```python
import dask


@dask.delayed
def ma_fonction(x, y=1):
    # Faire des trucs qui
    # prennent du temps ici
```

⇔

```python
def f(x, y=1):
    # Faire des trucs qui
    # prennent du temps ici


ma_fonction = dask.delayed(f)
```

- Déclare que la fonction sera exécutée en **asynchrone**

Calcul asynchrone en Python

Utilisation de la librairie `dask`

```python
import dask

@dask.delayed
def ma_fonction(x, y=1):
    # Faire des trucs qui
    # prennent du temps ici

x = ma_fonction(3)
y = ma_fonction(x)
z = x + y
valeur_z = z.compute()
```

- Ici, le calcul ne commence qu'à la ligne `z.compute()`
  - Les lignes précédentes ne sont pas bloquantes
- Dask se charge de construire le graphe des tâches à effectuer
  - Possible de le visualiser avec `z.visualize()`

Calcul asynchrone en Python

Utilisation de la librairie `dask`

```python
import dask

@dask.delayed
def ma_fonction(x, y=1):
    # Faire des trucs qui
    # prennent du temps ici

x = ma_fonction(3)
y = ma_fonction(x)
z = x + y
valeur_z = z.compute()
```

- Le type de `x, y, z` est modifié
  - Permet le `.compute()`
  - Opérations usuelles associées au type de base restent (ex : `x + y`)

Calcul asynchrone en Python

Utilisation de la librairie `dask`

```
import dask

@dask.delayed
def ma_fonction(x, y=1):
    # Faire des trucs qui
    # prennent du temps ici

x = ma_fonction(3)
y = ma_fonction(x)
z = x + y
z_val, x_val = dask.compute(z, x)
```

- Pour récupérer des valeurs de plusieurs variables : `dask.compute()`

Calcul asynchrone en Python

Utilisation de la librairie `dask`

- Exercice : implémentez l'exemple de début du cours à l'aide de `dask`

(3 + 7) * (2 + 8) * ((2 * 3) - 1)

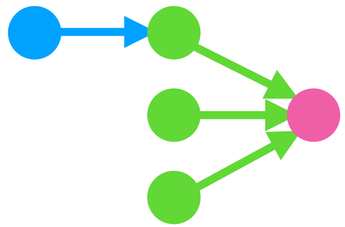

Collections spécifiques à `dask`

- Data Science
  - Types massivement utilisés
    - `np.array`
    - `pd.DataFrame`
- Dask propose des réimplémentations de ces types
  - Pour les cas où les données ne tiennent pas en mémoire
  - Pour paralléliser les traitements
- *Lazy evaluation*: chargement des données, calculs, *etc.* exécutés au moment du `.compute()`

`dask.array`

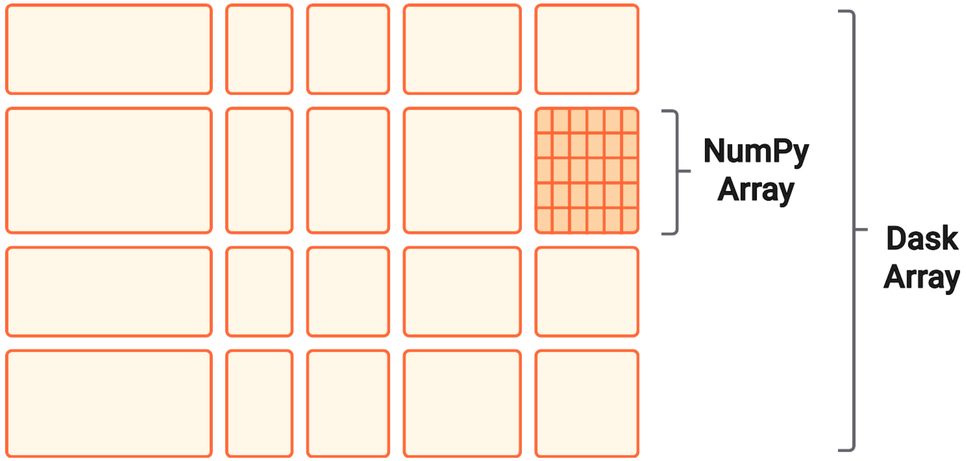

- Principe
  - Ensemble de blocs
    (découpage selon chaque dimension)
  - 1 bloc = 1 `np.array`
- Calculs parallèles
  - Utilise tous les coeurs disponibles par défaut
  - Réimplémentation des algorithmes standards par bloc
- Possible d'allouer des array plus grands que la mémoire

`dask.DataFrame`

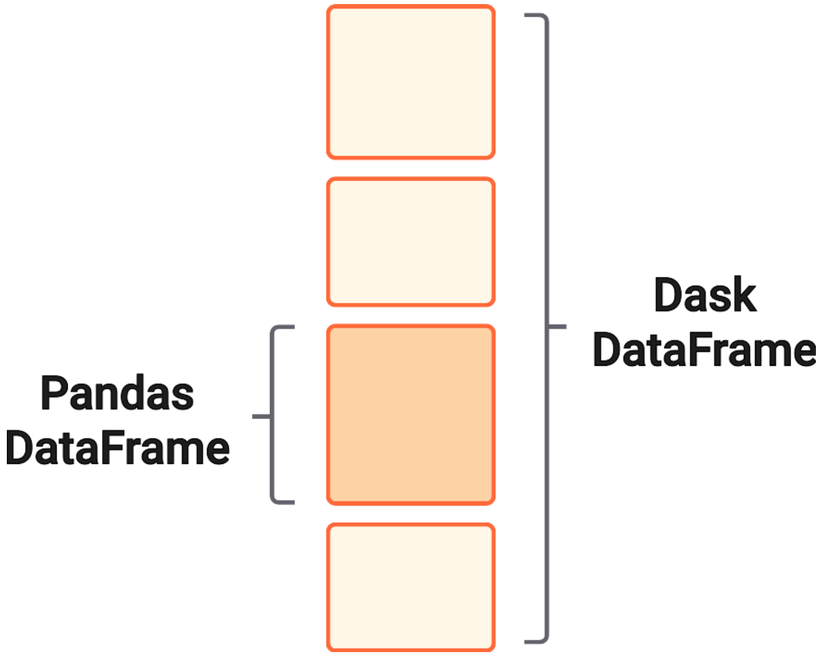

- Principe
  - Ensemble de blocs
    (1 bloc = 1 ensemble d'individus)
  - 1 bloc = 1 `pd.DataFrame`
- Même logique que `dask.array`
  - Calculs parallèles par bloc
  - Réimplémentation des fonctions `pandas` usuelles

Calcul distribué avec dask

Les clients en Dask

- Dask permet de spécifier où s'exécutent les calculs
  - Par défaut (si pas de client instancié), en local, en utilisant tous les coeurs disponibles
  - Possibilité de se connecter à un cluster
    - Calculs distribués
    - Code facilement adaptable

```
from dask.distributed import Client, SSHCluster

cluster = SSHCluster(…)
client = Client(cluster)

[…] # Code utilisant dask

del client
```