# SPARK


M. Ben & R. Tavenard

# Spark, qu'est-ce que c'est ?

- Framework de calculs distribués pour le big data
  - Analyse de données
  - Data science
  - Machine learning

- Support multi-langages
  - Scala (langage natif)
  - Java
  - Python (PySpark)
  - R

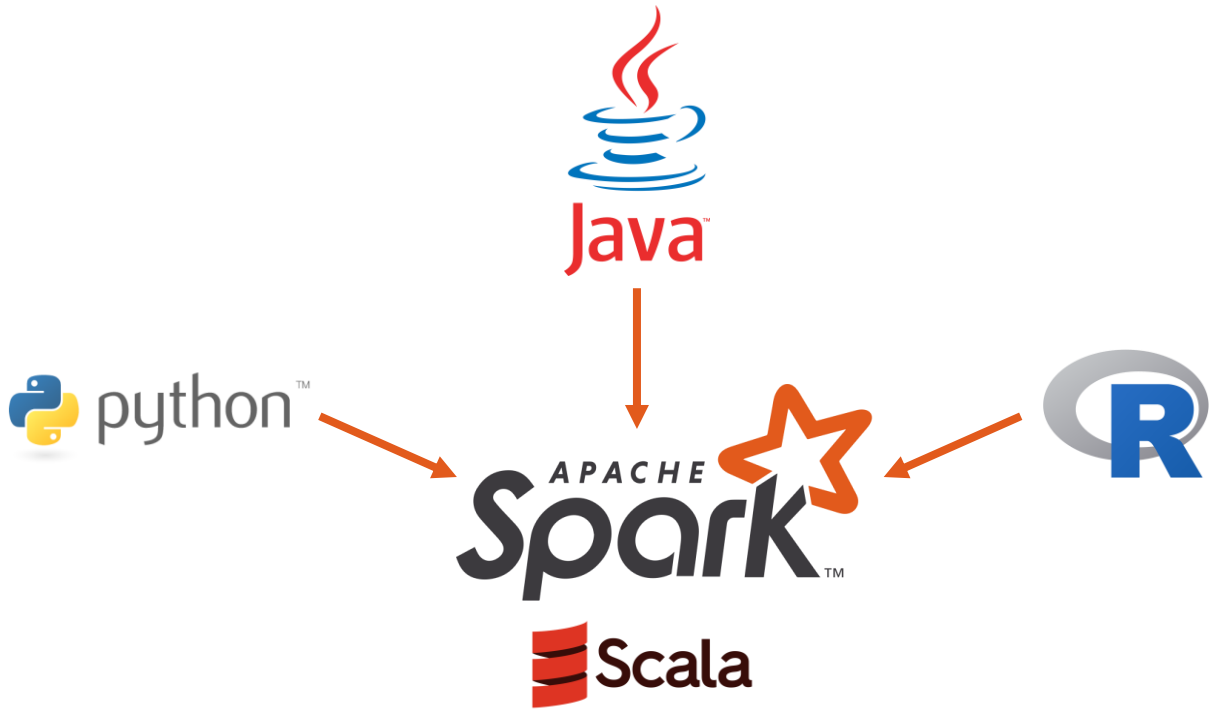


- Utilise des machines virtuelles Java
  - Nécessite une installation Java sur les machines

# Spark : caractéristiques

- Evolutif et flexible
  - Calculs sur machine unique ou sur cluster extensible (ex : cluster Hadoop)
- Rapide
  - Calculs sur données distribuées **en RAM**
  - Jusqu'à 100x plus rapide que Hadoop MapReduce
- Tolérant aux fautes
  - Procédé de reconstruction des données
- Largement compatible avec les outils de gestions de données
  - Systèmes de stockage
  - Bases de données
  - Outils de flux de données

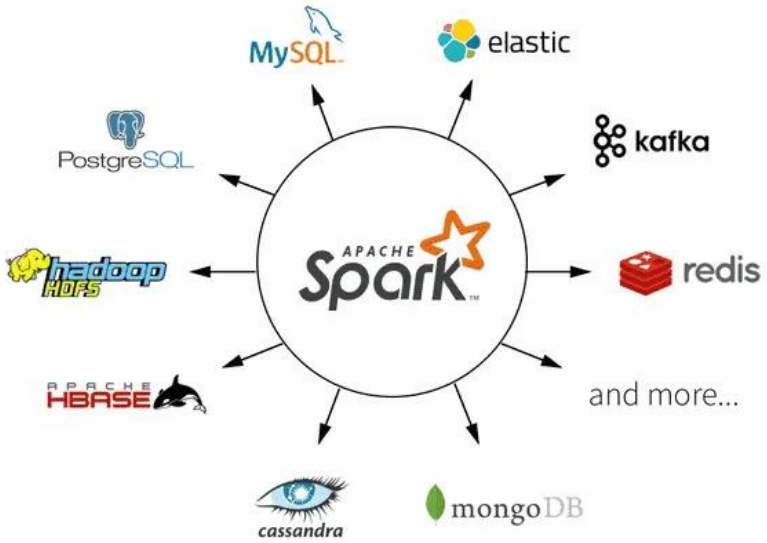


*source : https://www.databricks.com*

# Les RDDs de Spark

- *Resilient Distributed Dataset*

- Collection de données distribuée **en mémoire RAM** sur plusieurs machines
  - Structure sous-jacente de tous les types de donnée Spark

- Traitements sur un RDD
  - se font en parallèle
  - sont distribués sur les machines contenant les différentes **partitions** du RDD

- Un RDD est immuable
  - Les transformations appliquées à un RDD construisent un **nouveau** RDD

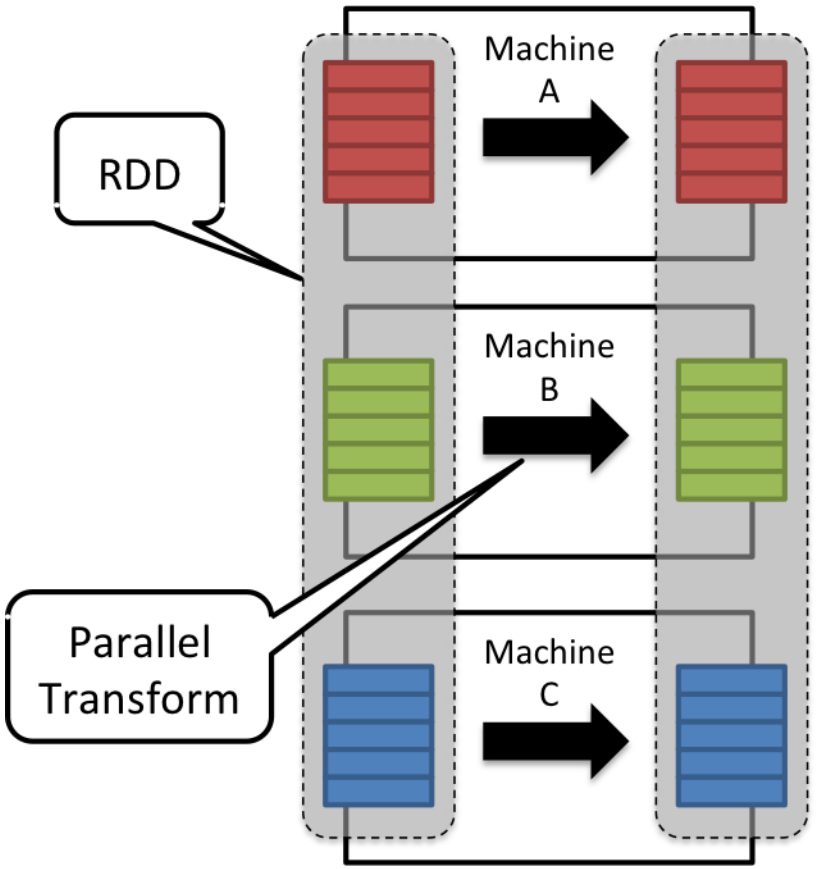


*source : https://vivani.net*

# Distribution des calculs

- *Driver Program*
  - Programme principal
  - Envoyé sur les nœuds de calcul
  - Contient un objet *SparkContext*
    - ➢ Connexion au cluster
    - ➢ Création et gestion des RDDs
- *Cluster Manager* (sur *Master Node*)
  - Gestion des ressources du cluster
    - ➢ Ex. : *Spark Standalone* ou *Hadoop YARN*
- *Worker Nodes*
  - Nœuds de calcul
  - Exécutent une partie des traitements
  - Traitent la sous-partie des données (partition) hébergée sur la machine

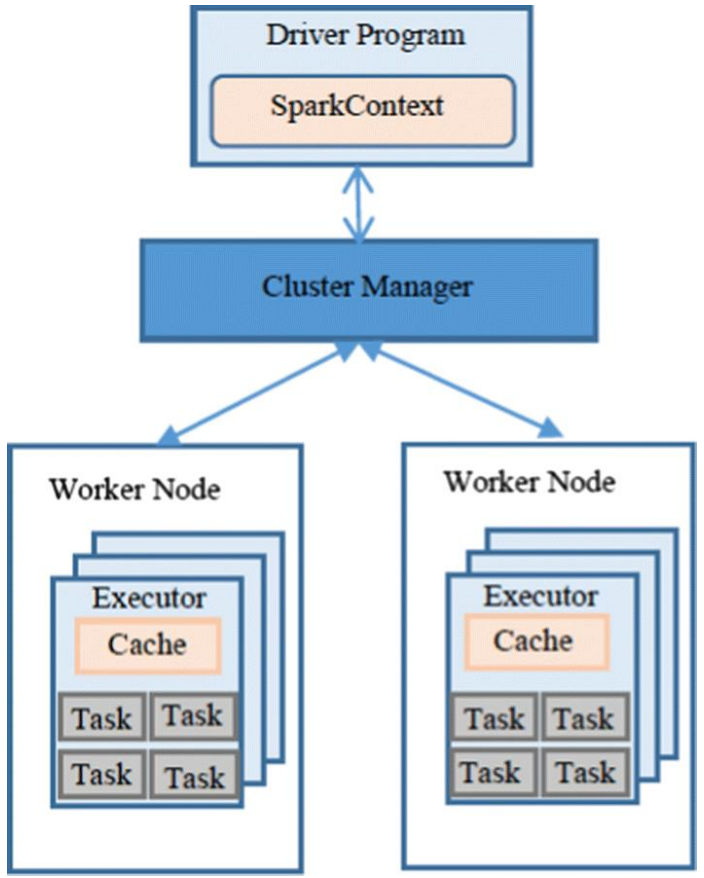


*source : https://journalofbigdata.springeropen.com*

# Mode d’utilisation de Spark

- Mode local
  - le *driver program* reste sur la machine locale
  - Spark utilisé comme framework de calculs parallélisés ou pour des tests
- Mode client
  - session connectée au cluster depuis la machine utilisateur
  - *driver program* sur machine utilisateur et envoyé sur les *worker nodes*
  - pour session interactive, tests ou traitements courts sur le cluster
- Mode cluster
  - *driver program* envoyé sur le *master node* (machine « maître » du cluster) et sur les *worker nodes*
  - fonctionne de façon autonome sur le cluster
  - mode utilisé pour un système en production

# Opérations sur les RDDs

- Deux types d'opération sur les RDDs
  1. Transformation
     - construit un nouveau RDD
     - *lazy evaluation* :
       - transformations « enregistrées » mais traitement retardé
       - créent un graphe d'opérations du RDD (*RDD lineage*)
       - Le *RDD lineage* est conservé pour pouvoir reconstruire les données en cas de défaillance
  2. Action
     - lance les traitements des transformations enregistrées
     - renvoie une valeur/liste de valeurs au *driver program* ou écrit sur disque

# Transformations & Actions sur les RDDs (Core API)

- Transformations
  - *Narrow transformations*
    - ➢ sans transfert de données
      - `map()`
      - `mapPartition()`
      - `flatMap()`
      - `filter()`
      - …
  - *Wide transformations*
    - ➢ avec transfert de données entre *worker nodes*
      - `groupByKey()`
      - `reduceByKey()`
      - `join()`
      - …
- Actions
  - ➢ nécessitent un transfert de données vers le *driver program*
    - `collect()`
    - `reduce()`
    - `count()`
    - `countByKey()`
    - `take(n)`
    - `foreach()`
    - `saveAsTextFile(path)`
    - …

# Les librairies haut niveau de Spark

- Spark SQL
  - DataFrames Spark
  - Support SQL


- Pandas-on-Spark API
  - API Pandas sur Spark (support incomplet)


- MLlib
  - Machine Learning


- GraphX
  - Analyse de graphes


- Spark Streaming
  - Traitements de flux de données

# PySpark Core RDD API

- Installation de PySpark
  ```
  pip install pyspark
  ```

- Import de la classe `SparkSession` du module `pyspark.sql`
  ```
  from pyspark.sql import SparkSession
  ```

- Objet `SparkSession`

  - Objet du *driver program* permettant les échanges avec
    - le *cluster manager*
    - les *worker nodes* du cluster

  - Contient un objet `SparkContext`
    - Support pour les RDDs

# PySpark Core RDD API

- Création d'une `SparkSession`
  - En local

```
spark = SparkSession.builder \
        .appName("Mon appli Spark") \
        .master("local[2]") \   # ou local[*] (utilise tous les coeurs)
        .getOrCreate()
```

  - Sur un cluster Spark

```
spark = SparkSession.builder \
        .appName("Mon appli Spark") \
        .master("spark://master-name:7077") \
              .getOrCreate()
```

- Arrêt de la `SparkSession`
  - Arrête le `SparkContext` sous-jacent : à placer à la fin du *driver program*

```
spark.stop()
```

# PySpark Core RDD API

- Création et manipulation d'un `RDD`
  - Récupération de l'objet `SparkContext` de la `SparkSession`

```
sc = spark.sparkContext
```

  - Création

```
rdd1 = sc.parallelize([0,1,2,3,4])          # à partir d'une liste Python
rdd2 = sc.range(100, 200, 10)               # à partir d'un range Spark
rdd3 = sc.textFile(<local or HDFS path>) # à partir d'un fichier texte
```

  - Manipulation (méthodes des objets `RDD`)
    - Informations et gestion : `getNumPartitions()`, `repartition()`, `cache()`,…
    - Transformations : `map()`, `flapMap()`, `filter()`,…
    - Actions : `collect()`, `count()`, `reduce()`, `saveAsTextFile(<path>)`,…
    - Voir la documentation en ligne

# PySpark SQL API

- Support `DataFrame` Spark et SQL

- `DataFrame` Spark
  - Données tabulaires distribuées
  - Associée à un schéma : typage des données par colonne
    - peut être défini explicitement
    - ou inféré automatiquement

- Tables SQL Spark
  - Créées à partir de `DataFrames` Spark
  - Manipulation et interrogation avec le langage SQL
    - génère de nouvelles `DataFrames` Spark (résultat de la requête)

# PySpark SQL API

- RDD *vs* DataFrame

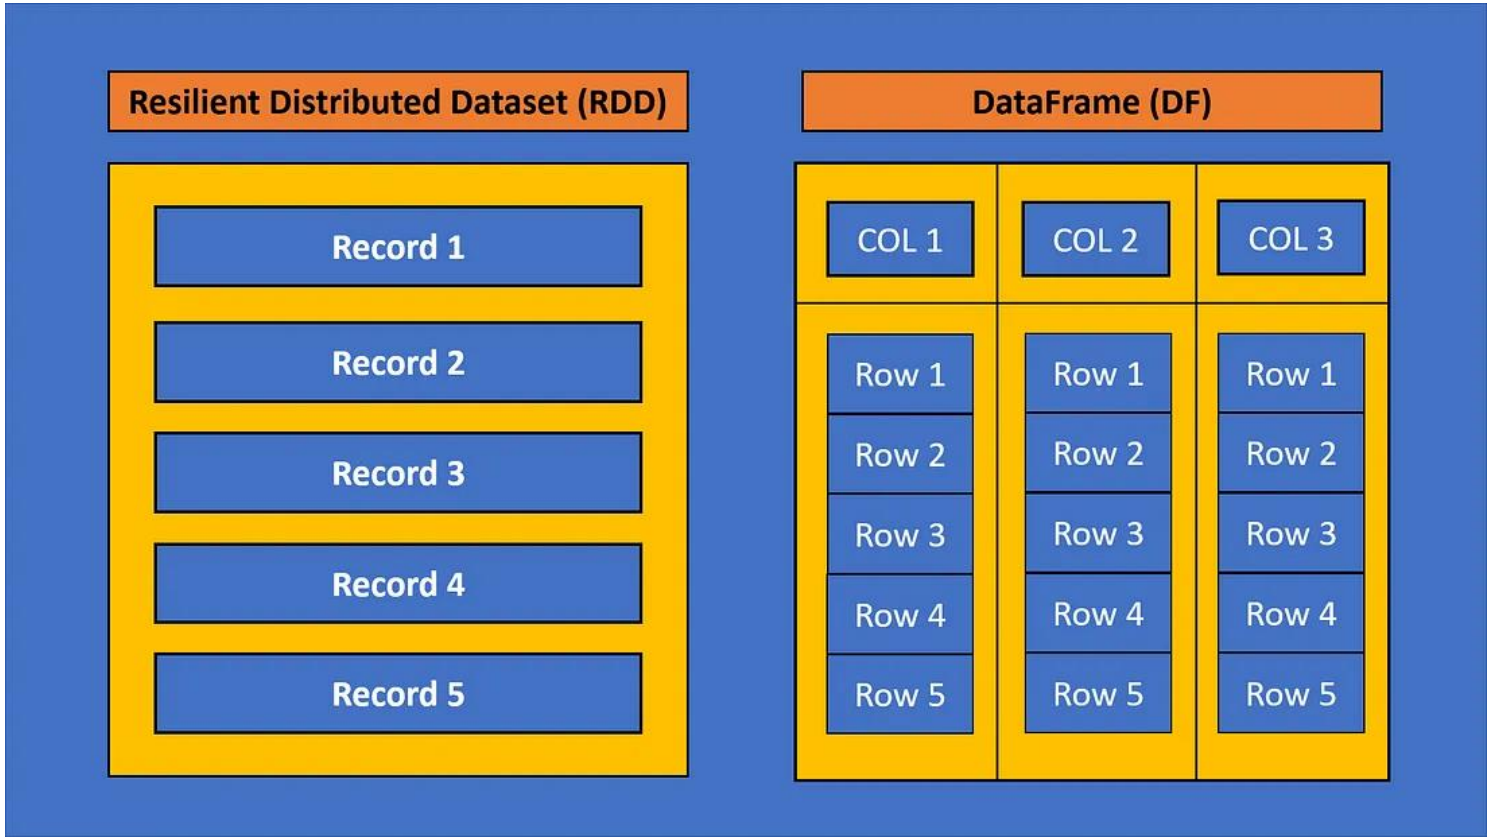


*source : https://levelup.gitconnected.com*

# PySpark SQL API

- Création d'une `DataFrame` Spark
  - Avec la méthode `createDataFrame` de la `SparkSession`

```
sdf1 = spark.createDataFrame(source, [schema], *options)
# source : collection Python, RDD, liste de Row, Dataframe Pandas…
```

  - Lecture depuis un fichier avec l'objet `SparkSession.read`

```
sdf2 = spark.read.csv(<path to CSV file>, [schema], *options)
sdf3 = spark.read.json(<path to JSON file>, [schema], *options)
sdf4 = spark.read.text(<path to TEXT file>, *options)
```

- Visualisation du contenu
  - Opération de type « action » (transfert des données au *driver program*)

```
sdf1.show()   # ou sdf1.show(n=10) pour les 10 premières lignes
```

# PySpark SQL API

- Manipulation des `DataFrame` Spark
  - Transformations
    - Valeurs : `replace`
    - Colonnes : `select`, `drop`, `withColumns`, `toDF`, …
    - Lignes : `filter`/`where`, `distinct`, `sort`, `orderBy`, `foreach`, …
    - Table : `join`, `intersect`, `union`, `transform`, `createOrReplaceTempView`, …
    - Groupes : `groupBy` (`GroupedData`), `agg`, `avg`/`mean`, `count`, `max`, `min`, `sum`, …
  - Actions
    - Récupération & visualisation : `show`, `collect`,…
    - Agrégation : `count`, `agg`, …
  - Informations, schéma, `RDD` sous-jacent
    - `summary`, `schema` (`StrucType`), `printSchema`, `to`, `rdd`, …
  - Écriture
    - Vers stockage externe : `write`

# PySpark SQL API

- Fonctions du module `functions`
  - Beaucoup prennent en paramètre(s) une ou plusieurs colonnes (nom ou objet `Column`)
  - Import :

```
from pyspark.sql import functions as sf
```

  - Catégories de fonctions :
    - Récupération et création de colonnes : `col`, `lit`, …
    - Fonctions mathématiques : `sqrt`, `log`, `pow`, `round`, …
    - Agrégation : `avg`, `count`, `min`, `max`, `std`, `sum`, …
    - Chaînes de caractères : `lower`, `upper`, `contains`, `substr`, `split`, …
    - Dates : `curdate`, `date_format`, `year`, `month`, …
  - Voir la documentation complète en ligne
- Manipulation des objet `Column`
  - Méthodes : `alias`, `astype`/`cast`, `between`, `contains`, `asc`, `desc`, `substr`, …
  - Voir la documentation complète en ligne

# Pandas-on-spark API

- Portage de l'API Pandas sur Spark
  - `DataFrame` et `Series` de type Pandas mais **distribuées**
  - Mêmes noms de méthodes/fonctions que Pandas

- Attention : support incomplet
  - Certaines fonctionnalités trop « couteuses » sur un cluster n'existent pas
  - Voir les méthodes et paramètres supportés

- Import

```
import pyspark.pandas as ps
```

# Pandas-on-spark API

- Création des `DataFrame` pandas-on-spark

```
# à partir d'un range (une colonne)
psdf1 = ps.range(1, 10, 2)

# à partir d'une structure de donnée Python
psdf2 = ps.DataFrame({'A':[1,2,3], 'B':['un','deux','trois']})

# à partir d'une Dataframe Pandas
psdf3 = ps.DataFrame(pdf)  # pdf est une DataFrame Pandas

# à partir d'une DataFrame Spark
psdf3 = ps.DataFrame(sdf)  # pdf est une DataFrame Spark

# à partir d'un RDD Spark
psdf3 = ps.DataFrame(rdd.toDF())  # rdd est un RDD Spark

# à partir d'un fichier
psdf4 = ps.read_csv(<path to CSV file>, sep=';')
psdf5 = ps.read_json(<path to JSON file>)
psdf6 = ps.read_parquet(<path to PARQUET file>)
...
```

# Pandas-on-spark API

- Manipulation des objets pandas-on-spark
  - Même API que Pandas (support partiel)
  - Voir la documentation en ligne :
    - `DataFrame`
    - `Serie`
    - `GroupBy`